

lunes, 10 de julio de 2023

Informe - Conclusión

TP 2 - Análisis Inteligente de Datos

En el presente trabajo se analizó una base de datos con información sobre diferentes aspectos relacionados al sueño y los hábitos de vida de las personas. En una primera instancia se generó una muestra aleatoria estratificada por la variable "Sleep Disorder" (n=300) con diferentes tamaños para cada categoría (para la categoría "None" se tomaron 180 datos mientras que para "Sleep Apnea" y "Insomnia" se tomaron 60 datos). Luego se abrió la columna "Blood Pressure" en otras dos "Cystolic Pressure" y "Diasstolic Pressure".

Tras tomar la muestra se procedió con una serie de análisis, tanto supervisados como no supervisados. Entre las técnicas de aprendizaje no supervisado, se llevó a cabo un análisis de componentes principales (PCA). Esta técnica tiene como objetivo la reducción de la dimensionalidad al reemplazar las variables iniciales del conjunto de datos por combinaciones lineales de las mismas (componentes). Estas nuevas variables explican un porcentaje dado de la varianza del problema original. Tras llevar a cabo el análisis se obtuvieron 9 componentes que las cuales las 3 primeras lograron explicar el 85,6% de la varianza total. Esto sugiere que la información más relevante o significativa de las variables originales se encuentra concentrada en esas tres componentes principales. Por otra parte, el gráfico de las 2 primeras componentes evidenció una alta correlación entre ciertas variables por el ángulo pequeño entre vectores ("Cystolic pressure" y "Diastolic pressure", "Sleep Duration" junto "Quality of Sleep" y "Daily Steps" junto "Physical Activity Level" mostraron una correlación elevada).

A continuación se llevó a cabo un Análisis de Correspondencias Simples, una técnica exploratoria que no requiere del cumplimiento de supuestos para su aplicación. Esta técnica permite ver cómo correlacionan pares de variables cualitativas (en este caso, "BMI Category" y "Sleep Disorder"). Por otro lado, este análisis permite realizar biplots que permite ver gráficamente asociación de variables según cercanía. En este análisis puntual, se vio que la dimensión 1 generada estaría separando a las personas con pesos dentro del rango saludable ("Normal" y "Normal Weight", variables que podrían haberse agrupado) de las personas con sobre peso ("Overweight" y "Obese"), además se vieron separadas por este eje las personas con desórdenes del sueño ("Sleep Apnea" y "Insomnia") de las que no padecen este tipo de desórdenes. Más aún, por cercanía entre ellas y lejanía respecto al origen, podría pensarse que los desórdenes del sueño están asociados al sobrepeso.

Se procedió con un Análisis de Correspondencias Múltiples (ACM) que, al igual que en el ACS, se trata de una técnica exploratoria pero que puede ser aplicada a una tabla de contingencia que involucra más de dos variables categóricas. En este caso se seleccionaron las variables "Sleep Disorder", "Gender" y "BMI Category" (ahora sí agrupando la categoría "Normal Weight" y "Normal"). Analizando el biplot, teniendo en cuenta que estos resultados son explorativos, pareciera que hay una tendencia en mujeres a presentar sobrepeso y apneas del sueño por sobre los hombres. La variable insomnio no parece estar asociada a un género pero está muy alejada del perfil medio.

En cuanto al Análisis del Discriminante, es una técnica de clasificación utilizada para encontrar combinaciones lineales de las variables predictoras que mejor logran distinguir entre dos o más grupos predefinidos. En este caso se utilizó para clasificar pacientes según la variable “Sleep Disorder”. Para llevar a cabo esta tarea y comprobar la efectividad del método de clasificación se separó el conjunto de datos en entrenamiento y prueba.

Sin embargo, este análisis requiere el cumplimiento de los supuestos de normalidad multivariada, homocedasticidad e independencia para poder aplicarse con seguridad. Sin embargo, no se cumplió con los dos primeros supuestos para el dataset en cuestión, pero se procedió con el análisis de todas maneras, teniendo en cuenta que los resultados no iban a ser confiables. Pese a esta salvedad, el modelo hizo una buena distinción y clasificación de los datos (en base al gráfico y la tabla de doble entrada presentados en el informe).

Como alternativa al análisis discriminante como técnica de clasificación, se aplicó el algoritmo de máquinas de soporte vectorial, que a priori no requiere realizar ningún supuesto sobre la muestra. Con el fin de evitar “data leakage” se procedió escalando los datos del conjunto de entrenamiento y prueba. El objetivo de este algoritmo es encontrar un hiperplano de separación entre los dos grupos. Para los fines de este trabajo se decidió trabajar únicamente con un kernel lineal. Por otro lado se realizó un bucle para iterar diferentes valores de “threshold” (el umbral utilizado para tomar la decisión de clasificación) desde 0,1 a 0,95 con un incremento de 0,01 y evaluar el “accuracy” de la predicción en cada caso tanto para el conjunto de prueba como de entrenamiento. En este punto personalmente me llamó la atención que ambos gráficos estén perfectamente superpuestos, hubiese esperado que el gráfico del dataset de entrenamiento esté por encima del de prueba.

Seguido de esto se llevó a cabo el método de clasificación no supervisado “k-means”. Se trata de un algoritmo muy sensible a outliers. A fin de determinar el número óptimo de clusters, se utilizó el criterio del codo y el coeficiente silhouette. Sin embargo, el gráfico para efectuar el criterio del codo no mostró un resultado evidente (parecía haber un “codo” en 4) y el coeficiente de silhouette presentó un máximo en 9 y 10. Es por esto que se probó agrupar de 4 y de 9. En base a los resultados gráficos, el clustering de 4 pareció ser el más adecuado, puesto a que se separaron bien 3 grupos centrales (intuitivamente y teniendo en cuenta los resultados de otros ítems, parecían corresponder a “Sleep Apnea”, “Insomnia” y “None”).

Finalmente se llevó a cabo otro análisis de clasificación supervisada: K-NN. Se trata de un método de clasificación que busca en las observaciones más cercanas a la que se está tratando de predecir y clasifica el punto de interés basado en la mayoría de datos que le rodean. Para esto, similar al análisis de SVM, se realizó un bucle en el que se iteraron valores del 1 al 100 del hiperparámetro “k” (el número de vecinos más cercanos que se consideran para realizar la clasificación). Se puede observar que valores muy bajos de “k” llevan al sobre ajuste del modelo.

En conjunto, este trabajo permitió probar diferentes herramientas con diferentes objetivos como clasificar de forma supervisada y no supervisada o simplemente evaluar de forma exploratoria un conjunto de datos.